



## 铝型材表面瑕疵识别 --top1

第一部分：图像 EDA  
第二部分：基础模型  
第三部分：结构调整  
第四部分：损失函数  
第五部分：结果优化

标注数据可视化

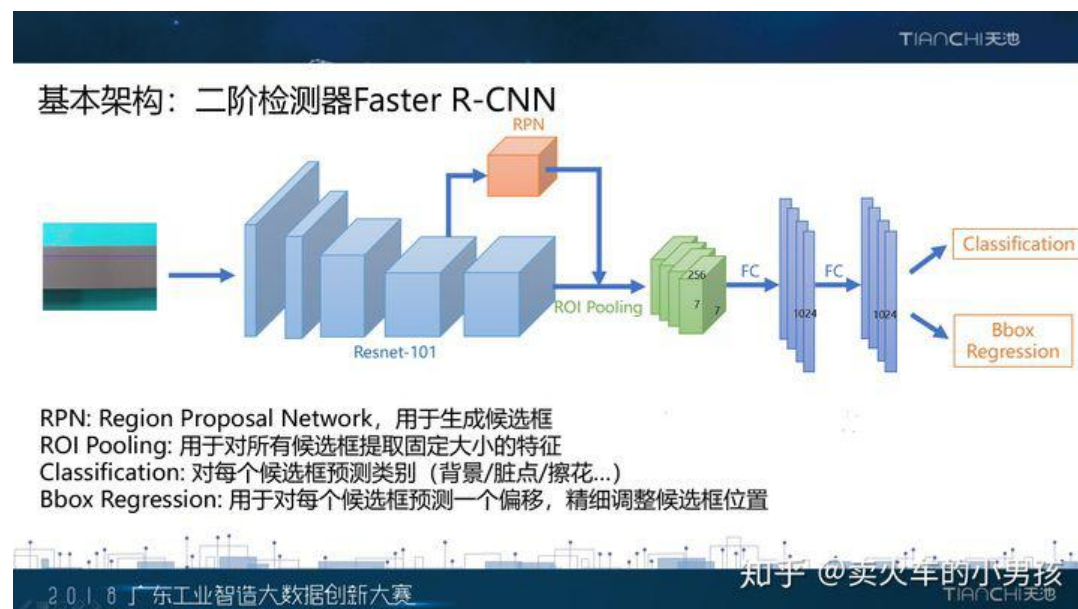


类别数量分布、目标区域分布

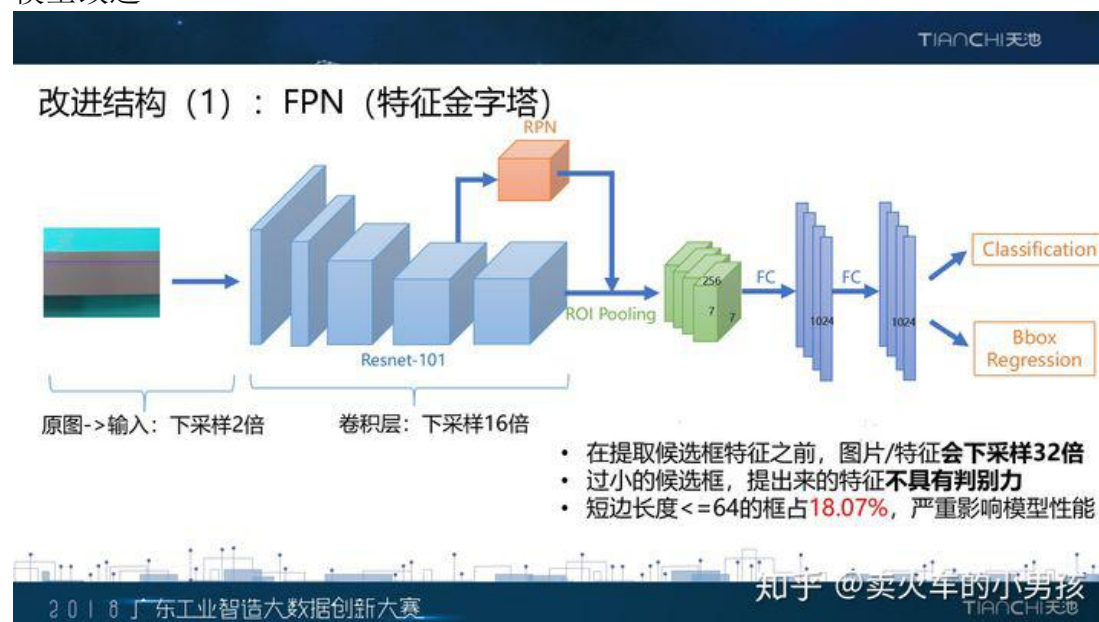


尺寸变化大，形状不固定，与背景差异小

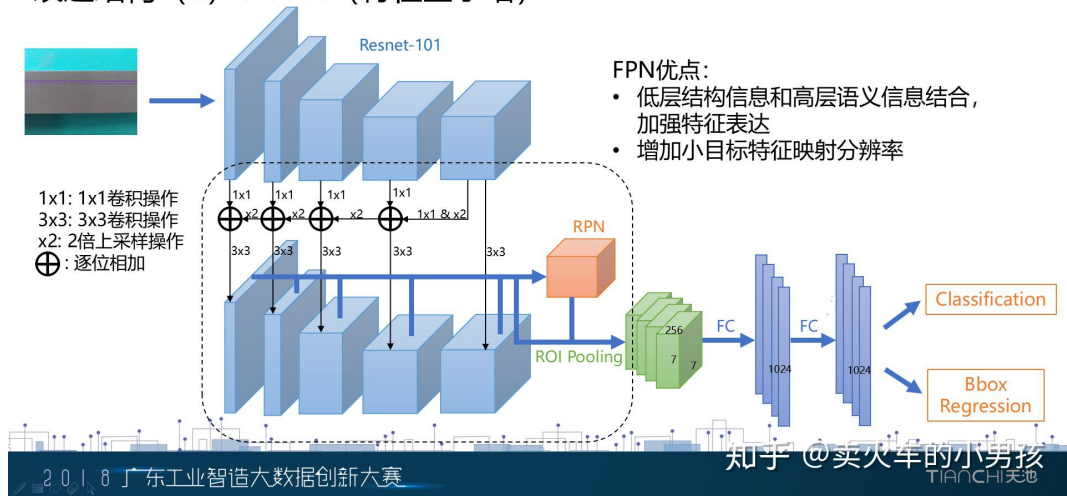
## Baseline 选择



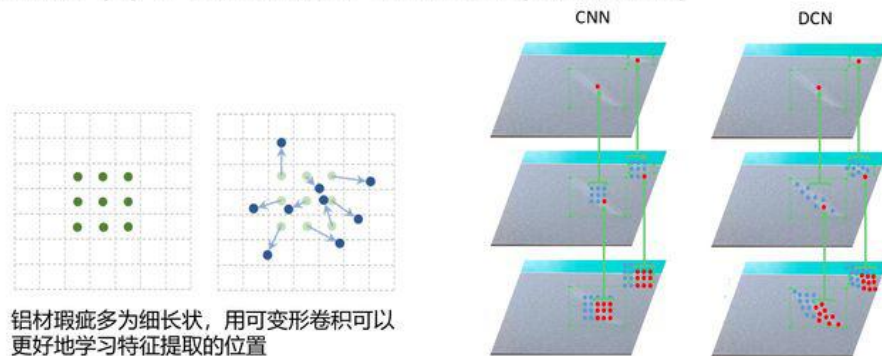
## 模型改进



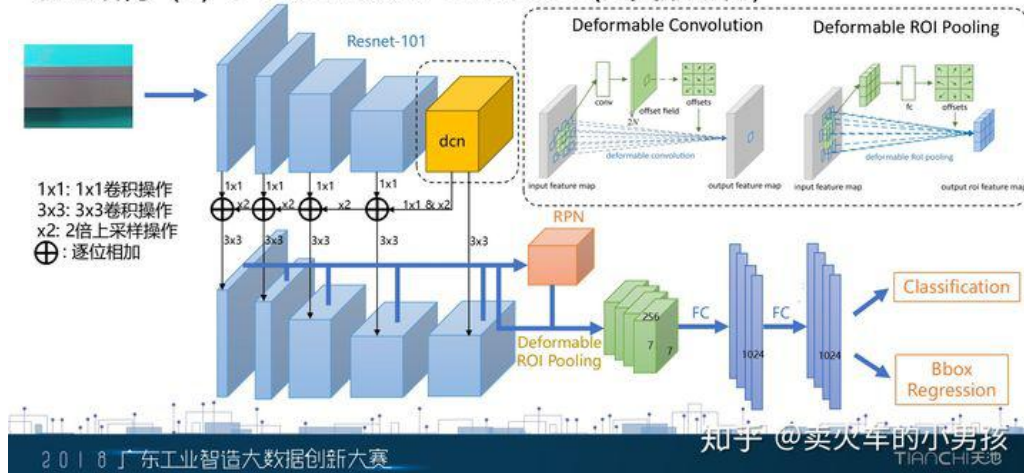
## 改进结构 (1) : FPN (特征金字塔)



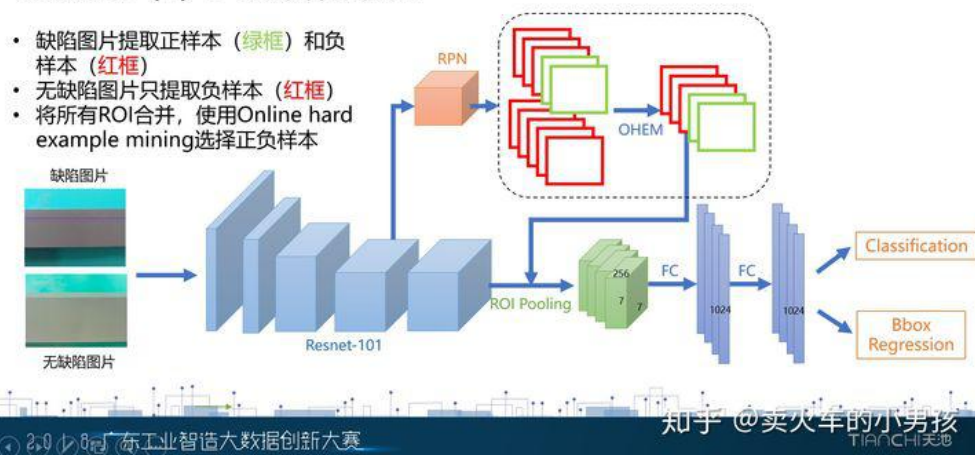
## 改进结构 (2) : Deformable-ConvNets (可变形卷积)




## 改进结构 (2) : Deformable-ConvNets (可变形卷积)







## 训练细节 (2) : 数据水平竖直翻转



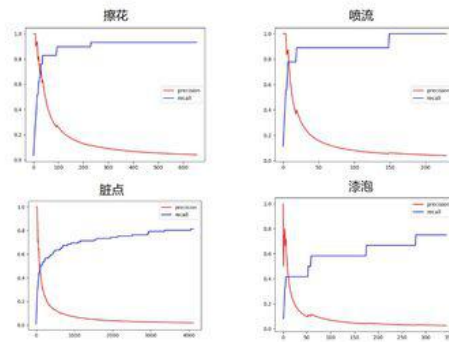

2018 广东工业智造大数据创新大赛

知乎 @买火车的小男孩

TIANCHI天池

## 结果分析

## 实验结果 (1) : 各类别效果



2018 广东工业智造大数据创新大赛

知乎 @买火车的小男孩

TIANCHI天池


## 实验结果 (2) : Softnms (软非极大值抑制)

Input :  $B = \{b_1, \dots, b_N\}$ ,  $S = \{s_1, \dots, s_N\}$ ,  $N_t$   
 $B$  is the list of initial detection boxes  
 $S$  contains corresponding detection scores  
 $N_t$  is the NMS threshold

```

begin
  D ← {}
  while B ≠ empty do
    m ← argmax S
    M ← b_m
    D ← D ∪ M; B ← B - M
    for b_i in B do
      if iou(M, b_i) ≥ N_t then
        B ← B - b_i; S ← S - s_i
      end
      s_i ← s_i * f(iou(M, b_i))
    end
  end
  return D, S
end
  
```

Softnms算法

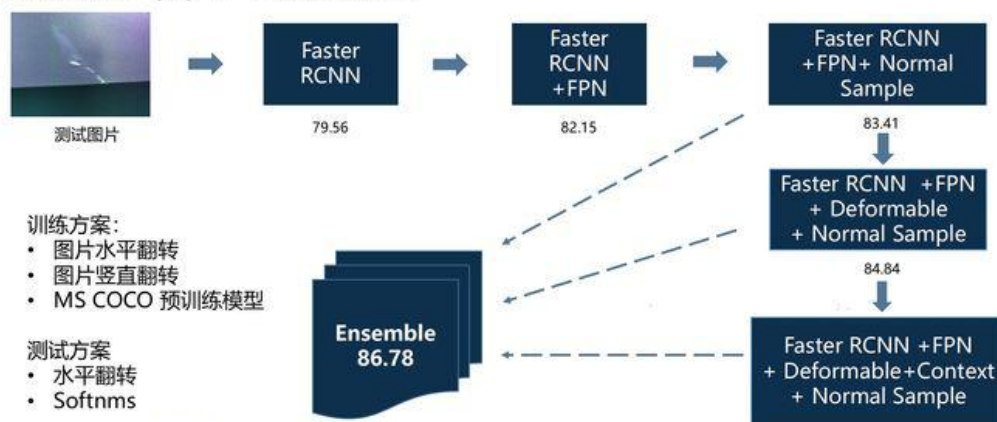


知乎 @买火车的小男孩

TIANCHI天池

2018 广东工业智造大数据创新大赛

## 实验结果 (3) : 各方案效果



2018 广东工业智造大数据创新大赛

知乎 @卖火车的小男孩

## 实验结果 (4) : 排行榜

A榜 Top1					C榜 Top1			
排名	参赛者	所在组织	分数		排名	参赛者	所在组织	分数 计算耗时
1	Are you ok ?	华南理工大学	86.78%		1	Are you ok ?	华南理工大学	81.64% 3027s
2	BOOMBOOM	西安交通大学	85.48%	↓ 1.30%	2	打怪升级	中国科学院	78.09% 7462s
3	私奔到月球	家里蹲	85.24%		3	BOOMBOOM	西安交通大学	78.06% 1831s
4	勤劳的张大师	四川大学	85.24%		4	都都都都都	六都中学	77.36% 1114s
5	打怪升级	中国科学院	85.21%		5	风不动	北京邮电大学	77.36% 14018s
6	都都都都都	六都中学	84.37%	↓ 2.41%	6	shuzhilian_ai	szl	76.93% 7104s

B榜 Top1				
排名	参赛者	所在组织	分数	
1	Are you ok ?	华南理工大学	81.72%	
2	BOOMBOOM	西安交通大学	80.55%	↓ 1.17%
3	都都都都都	六都中学	79.27%	
4	打怪升级	中国科学院	78.97%	
5	shuzhilian_ai	szl	78.97%	
6	风不动	北京邮电大学	78.86%	↓ 2.86%

1 在测试集A、B、C中, 我们长期处在Top1的位置

2 在C榜中, 我们的模型成绩比第二名高3.5个百分点

2018 广东工业智造大数据创新大赛

知乎 @卖火车的小男孩



## 总结与展望

### 总结:

- 1 对正常样本以及各瑕疵样本的充分挖掘, 提高了模型的鲁棒性
- 2 使用fpn、dcn等结构, 缓解了瑕疵形状与尺度的多变问题
- 3 引入context信息, 进一步提高了模型对瑕疵位置的定位
- 4 单模型上具有非常优异的性能, 是一个通用的高效率、高精度的缺陷识别方案

### 展望:

- 1 超小瑕疵的精确定位?
- 2 迁移到其他类似领域 (如手机盖板缺陷识别, 布匹缺陷识别)

2018 广东工业智造大数据创新大赛

知乎 @卖火车的小男孩  
TIANCHI 天池

## 参考文献

- Lin, Tsung Yi, et al. "Feature Pyramid Networks for Object Detection." (2016)
- Dai, Jifeng, et al. "Deformable Convolutional Networks." (2017).
- Girshick, Ross. "Fast R-CNN." (2015)
- Ren, Shaoqing, et al. "Faster R-CNN: towards real-time object detection with region proposal networks. (2015)
- He, K., et al. "Mask R-CNN. " IEEE Transactions on Pattern Analysis & Machine Intelligence PP.99(2017).
- Cai, Zhaowei, and N. Vasconcelos. "Cascade R-CNN: Delving into High Quality Object Detection." (2017).
- Bodla, Navaneeth, et al. "Improving Object Detection With One Line of Code." (2017).
- Yuan, Yuhui, and J. Wang. "OCNet: Object Context Network for Scene Parsing." (2018).
- 许浩均. "金属弧面工件表面缺陷检测与误检排除技术研究." (2017).
- Zeng, Xingyu, et al. Gated Bi-directional CNN for Object Detection. (2016).
- Mei, S, Y. Wang, and G. Wen. "Automatic Fabric Defect Detection with a Multi-Scale Convolutional Denoising Autoencoder Network Model." (2018).

2018 广东工业智造大数据创新大赛

知乎 @卖火车的小男孩  
TIANCHI 天池

[https://github.com/herbert-chen/tianchi\\_lvcai](https://github.com/herbert-chen/tianchi_lvcai)

[https://github.com/OdingdongO/pytorch\\_classification](https://github.com/OdingdongO/pytorch_classification)

## 团队简介



曾兆阳

中山大学 博士

FashionAI 季军  
JD猪脸识别 冠军

陈汉造

华南理工大学 硕士

FashionAI 亚军  
雪浪制造AI挑战赛 冠军

白德桃

西安交通大学 硕士


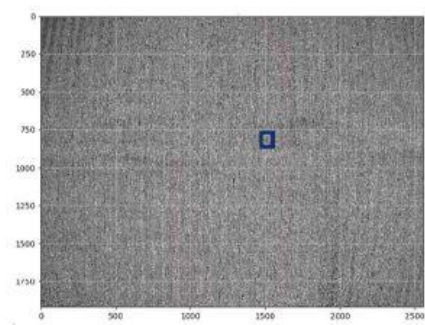
FashionAI 冠军  
雪浪制造AI挑战赛 冠军

2018 广东工业智造大数据创新大赛

知乎 @卖火车的小男孩  
TIANCHI天池

## 雪浪制造 AI 挑战赛(计算辅助良品检测)--top1 方案


TIANCHI天池




雪浪制造 AI 挑战赛

知乎 @卖火车的小男孩






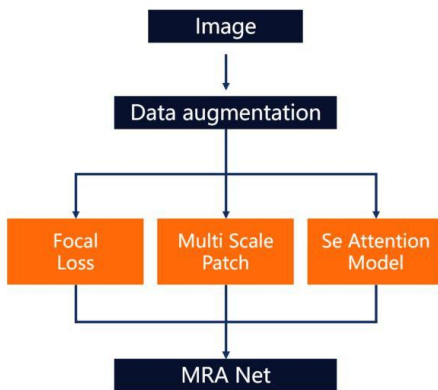
样本类别 **不平衡**



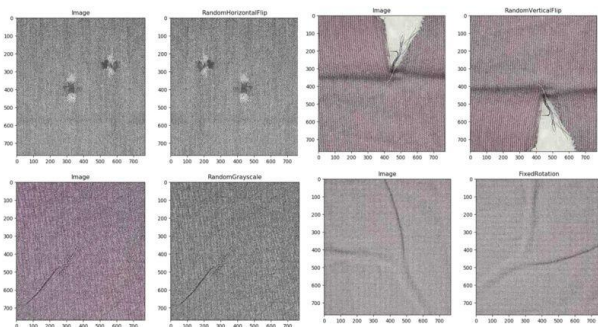
缺陷区域 **占比小**



缺陷尺度 **变化大**



### Data augmentation



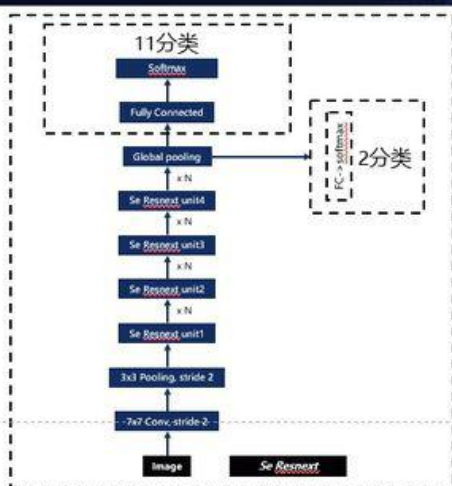
视觉计算辅助良品检验

助力工业制造良品提升


## 布匹缺陷智能识别

雪浪制造 AI 挑战赛

知乎 @卖火车的小男孩



Lin, Tsung Yi, et al. (2017). Hu, Jie, et al. (2017). Xie, Saining, et al. (2016).




$$\text{Online Score} = 0.7 * \text{AUC} + 0.3 * \text{mAP}$$

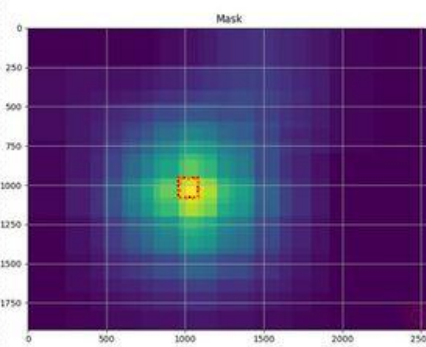


$$\text{Loss}_{\text{all}} = 0.7 * \text{Loss}_{11} + 0.3 * \text{Loss}_2$$

雪浪制造 AI 挑战赛


知乎 @卖火车的小男孩



缺陷区域 占比小




给出布匹合理的 缺陷概率 和 瑕疵区域



Hu, Jie, et al. (2017).



### 卷积核是一种信息聚合体

- 聚合 **空间信息** 和 **特征维度信息**  
spatial channel-wise
- 具有局部感受野



### Squeeze-and-Excitation (SE)

Hu, Jie, et al. (2017). He, Kaiming, et al. (2016).





Data	Model	Parameter Number	Input Size	Online Score	
				One model	Two model
Ori Image	resnext101	42.25M	768*1024	68.5	\
	Se resnext101	49.13M	768*1024	69.5	\
Single Patch	resnext101	42.25M	500*500	73.6	\
	Se resnext101	49.13M	500*500	74.8	76.5
Multi Scale Patch	resnext101	42.25M	500*500	\	\
	Se resnext101	49.13M	500*500	76.4	77.3

- 1 Patch特征在缺陷识别任务上性能远高于全图特征
- 2 Se Channel Attention抑制无用特征，进一步提升精度
- 3 多尺度Patch贴合缺陷尺寸变化情况，大幅提升模型性能


视觉计算辅助良品检验

助力工业制造良品提升

Multi-scale Regions Attention (MRA) Net  
for Defect Recognition

高效、高精度的端到端解决方案

### R-CNN vs. Fast R-CNN (forward pipeline)



Faster!



Faster!

	R-CNN	Fast R-CNN
Train Time	84 hours	9.5 hours
(Speedup)	1x	8.8x
Test time per image	47 seconds	0.32 seconds
(Speedup)	1x	146x

Girshick, Ross, et al. (2014). Girshick, Ross, et al. (2015).

雪浪制造 AI 挑战赛

知乎 @卖火车的小男孩



$$i_o = g_L(i_L) = \alpha_L(i_L - 1) + \beta_L$$

$$\alpha_L = \prod_{p=1}^L S_p$$

$$\beta_L = 1 + \sum_{p=1}^L \left( \prod_{q=1}^{p-1} S_q \right) \left( \frac{F_p - 1}{2} - p_p \right)$$

简化版

$$p_i = S_i * p_{i+1}$$

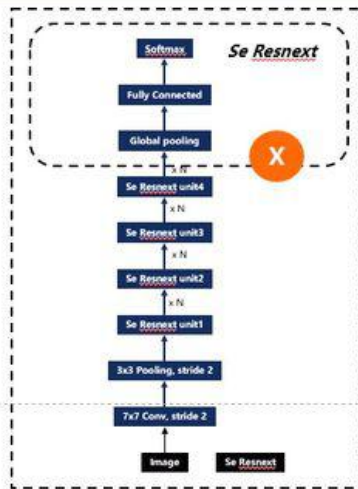
$$p_0 = S * p_{i+1} \left( S = \prod_0^i S_i \right)$$

Feature Maps = features + locations

Girshick, Ross, et al. (2015). He, Kaiming, et al. (2014).

雪浪制造 AI 挑战赛

知乎 @卖火车的小男孩





Se Patch net



Outputs

Feature Map

Image



He, Kaiming, et al. (2014).

		Scale1	Scale2	Scale3
Ori Image (2560*1920)	Patch Size	960	800	640
	stride	160	160	160
Input Image (1024*768)	Patch Size	384	320	10
	stride	64	64	64
Feature Map (32*24)	Kernel Size	12	10	8
	stride	2	2	2
Outputs	size	11*7	12*8	13*9

	Model	Parameter Number	Input Size	Test time per image	Speed up	Online Score	
						One model	Two model
Single Scale	Se resnext101	49.13M	(384*384)*77	2.56s	1x	74.8	\
	MRA Net	47.09M	768*1024	0.114s	22.5x	75.1	\
Multi Scale	Se resnext101	49.13M	(384*384)*290	9.65s	1x	76.4	77.30
	MRA Net	47.09M	(768*1024)*1	0.118s	81.77x	76.2	77.27

- 1 精度上，MRA Net与数据Patch方法不相上下
- 2 速度上，MRA Net比数据Patch有了近百倍的提升
- 3 MRA Net 是一个高效、高精度的缺陷检测网络

## References

- Lin, Tsung Yi, et al. "Focal loss for dense object detection." (2017)
- Hu, Jie, L. Shen, and G. Sun. "Squeeze-and-Excitation Networks." (2017).
- Girshick, Ross. "Fast R-CNN." (2015)
- Ren, Shaoqing, et al. "Faster R-CNN: towards real-time object detection with region proposal networks. (2015)
- Ross Girshick, et al. "Region-based Convolutional Networks for Accurate Object Detection and Segmentation." (2014).
- He, Kaiming, et al. "Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition." (2014)
- Girshick, Ross, et al. "Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation." (2014).
- He, Kaiming, et al. "Deep Residual Learning for Image Recognition." (2016).
- Xie, Saining, et al. "Aggregated Residual Transformations for Deep Neural Networks." (2016)
- Wang, Fei, et al. "Residual Attention Network for Image Classification." (2017)
- Woo, Sanghyun, et al. "CBAM: Convolutional Block Attention Module." (2018).





白德桃

西安交通大学  
2018天池

**FashionAI 冠军** 队长



陈汉造

华南理工大学  
2018天池

**FashionAI 亚军** 队长



王博

西安电子科技大学  
2018天池

**天文大赛 top5** 核心队员



盛爱林

四川大学  
2018天池ATEC

**风险大脑 亚军** 核心队员

## 39 场 Kaggle 比赛之后，有人总结了一份图像分割炼丹

这份列表分为十大板块，包括外部数据、预处理、数据增强、建模、硬件配置、损失函数、训练技巧、评估和交叉验证、集成方法以及后处理。

### Contents

[External Data →](#)

[Preprocessing →](#)

[Data Augmentations →](#)

[Modeling →](#)

[Hardware Setups →](#)

[Loss Functions →](#)

[Training Tips →](#)

[Evaluation and Cross-validation →](#)

[Ensembling Methods →](#)

[Post Processing →](#)

# 目标检测 | 已开源！全新水下目标检测算法 SWIPENet+IMA 框架

2020-06-03 阅读 363。

论文地址: <https://arxiv.org/abs/2005.11552.pdf>

代码地址: <https://github.com/LongChenCV/SWIPENet>

近年来,基于深度学习的方法在标准的目标检测中取得了可喜的性能。水下目标检测仍具有以下几点挑战:(1)水下场景的实际应用中目标通常很小,含有大量的小目标;(2)水下数据集和实际应用中的图像通常是模糊的,图像中具有异构的噪声。

为了解决小目标检测和噪声这两个问题,本文首先提出了一种新颖的神经网络架构,即**用于小物体检测的样本加权混合网络(SWIPENet)**。SWIPENet 由高分辨率和语义丰富的超特征图组成,可以显著提高小物体检测的准确性。此外,提出了一种**新的样本加权损失函数**,该函数可以为 SWIPENet 建模样本权重,它使用一种**新颖的样本重新加权(Sample re-weighting)**算法,即**Invert Multi-Class Invert Adaboost (IMA)**,以减少噪声对提出的 SWIPENet 的影响。

在两个水下机器人拾取竞赛数据集 URPC2017 和 URPC2018 进行的实验表明,与几种最先进的目标检测方法相比,本文提出的 SWIPENet+IMA 框架在检测精度上取得了较好的性能。

## 简介

水下目标检测旨在对水下场景中的物体进行定位和识别。这项研究由于在海洋学、水下导航等领域的广泛应用而引起了持续的关注。但是,由于复杂的水下环境和光照条件,这仍然是一项艰巨的任务。

基于深度学习的物体检测系统已在各种应用中表现出较好的性能,但在处理水下目标检测方面仍然感到不足,主要有原因是:可用的水下目标检测数据集稀少,实际应用中的水下场景的图像杂乱无章,并且水下环境中的目标物体通常很小,而当前基于深度学习的目标检测器通常无法有效地检测小物体,或者对小目标物体的检测性能较差。同时,在水下场景中,与波长有关的吸收和散射问题大大降低了水下图像的质量,从而导致了可见度损失,弱对比度和颜色变化等问题。




Fig. 1. Exemplar images with ground truth annotations (left), results of Single Shot MultiBox Detector (SSD) (mid) [25] and our method (right). SSD cannot detect all the small objects while our method outperforms SSD in this case.


## 本文提出的方法：SWIPENet

卷积神经网络的下采样的使用能够带来强大的语义信息，从而导致许多分类任务的成功。然而，下采样操作对于目标检测任务来说是不够的，目标检测任务不仅需要识别物体的类别，而且还需要在空间上定位其位置。在应用了几次下采样操作之后会导致特征图的空间分辨率太粗糙，从而无法处理小物体的检测。

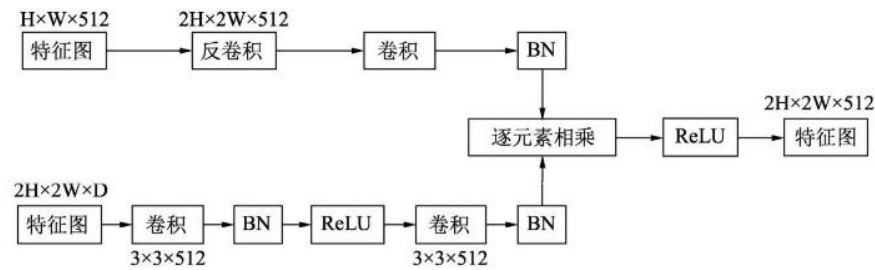
在本文中，提出了 SWIPENet 网络结构，该网络充分利用了受 DSSD 启发的几种高分辨率和语义丰富的 Hyper 特征图。

先来介绍一下 DSSD 网络。


SSD 利用了感受野与分辨率不同的 6 个特征图进行后续分类与回归网络的计算，DSSD 保留了这 6 个特征图，但在这 6 个特征图进一步进行了融合处理，然后将融合后的结果送入后续分类与回归网络，如下图所示。具体做法是，将最深层的特征图直接用作分类与回归，接着，该特征经过一个反卷积模块，并与更浅一层的特征进行逐元素相乘，将输出的特征用于分类与回归计算。类似地，继续将该特征与浅层特征进行反卷积与融合，共计输出 6 个融合后的特征图，形成一个沙漏式的结构，最后给分类与回归网络做预测。



DSSD 具体的反卷积模块如下图所示。这里深特征图的大小是  $H \times W \times 512$ ，浅特征图的大小为  $2H \times 2W \times D$ 。深特征图经过反卷积后尺寸与浅特征图相同，再经过一些卷积、ReLU 与 BN 操作后，两者进行逐元素的相乘，最后经过一个 ReLU 模块，得到最终需要的特征图。



在得到特征图后，DSSD 也改进了分类与回归的预测模块。SSD 的预测模块是直接使用  $3 \times 3$  卷积，而 DSSD 则对比了多种方法，最终选择了下图所示的计算方式，包含了一个残差单元，主路和旁路进行逐元素相加，然后再接到分类与回归的预测模块中。



可以看出，DSSD 通过多个上采样反卷积层增强了 SSD 目标检测框架，以提高特征图的分辨率。在 DSSD 体系结构中，首先，构造多个下采样卷积层以提取有利于对象分类的高语义特征图。经过几次下采样操作后，特征图太粗糙而无法提供足够的信息来进行精确的小对象定位，因此，添加了多个上采样反卷积层和 skip connection 来恢复特征图的高分辨率。但是，即使恢复了分辨率，下采样操作丢失的详细信息也无法完全恢复。

为了改进 DSSD，本文所提出的 SWIPENet 网络使用空洞卷积层来获得强语义信息，而不会丢失支持对象定位的详细信息。图 2 说明了提出的 SWIPENet 的基本结构，它由多个基本卷积块（红色），空洞卷积块（绿色），反卷积块（蓝色）和新的样本加权损失（灰色）组成。



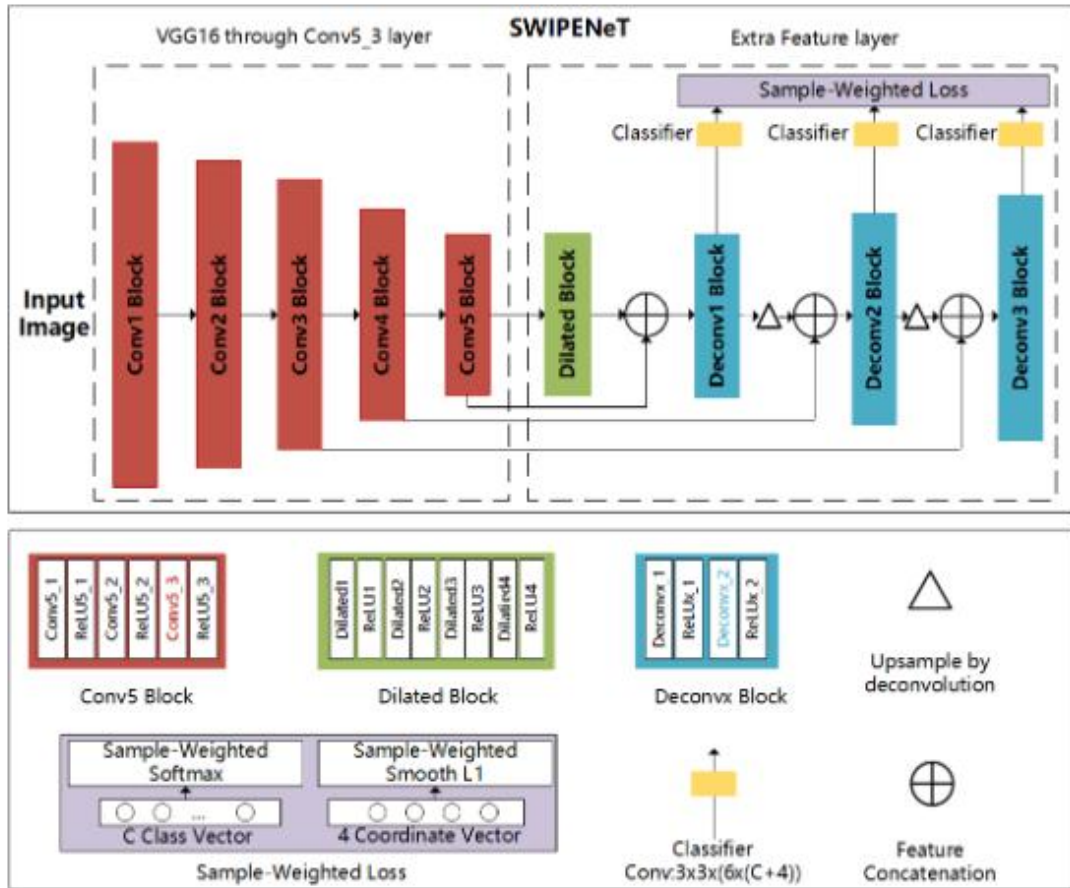


Fig. 2. The overview of our proposed SWIPENet.

SWIPENet 的主干网络采用的标准 VGG16 模型（在 Conv5<sub>3</sub> layer 上被截断）。与 DSSD 不同的是，在网络上添加了四个具有 ReLU 激活的空洞卷积层，可以在不牺牲特征图分辨率的情况下获得较大的感受野（较大的感受野会带来强语义信息）。同时，skip connection 将低层的精细细节传递给高层特征图。最后，在反卷积层上构造了多个 **Hyper Feature Map**。SWIPENet 的分类和回归预测模块上部署了三个不同的反卷积层，即 Deconv12，Deconv22 和 Deconv32（在图 2 中表示为 Deconvx2），它们的大小逐渐增加并预测多个尺度的对象。在三个反卷积层中定义了 6 个默认框和相对于原始默认框形状的 4 个坐标偏移，并使用 3×3 卷积产生  $C + 1$  类别的分数（ $C$  表示类别的数量，1 指示背景类）。

### Sample-weighting loss

本文提出了一种新颖的样本加权损失函数，可以在 SWIPENet 中对样本权重进行建模。样本加权损失使 SWIPENet 可以专注于学习高权重样本，而忽略低权重样本。它能够与新颖的样本加权算法 **Invert Multi-Class Invert Adaboost** 配合使用，通过减少权重来减少可能的噪声对 SWIPENet 的影响。

样本加权损失  $L$  由用于边界框分类的损失  $L_{cls}$  和用于边界框回归的损失  $L_{reg}$  组成， $L_{cls}$  使用 softmax 损失函数而  $L_{reg}$  使用 L1 平滑损失实现。

$$L = \frac{1}{Num} (\alpha_1 L_{cls}(pre\_cls, gt\_cls) + \alpha_2 L_{reg}(pre\_loc, gt\_loc)) \quad (1)$$

where

$$L_{cls} = - \sum_{i \in Pos} \sum_{c=1}^{C+1} f(\bar{w}_i^m) gt\_cls_i^c \log(pre\_cls_i^c) - \sum_{i \in Neg} \sum_{c=1}^{C+1} gt\_cls_i^c \log(pre\_cls_i^c) \quad (2)$$

$$L_{reg} = \sum_{i \in Pos} \sum_{l \in Loc} f(\bar{w}_i^m) SmoothL1(pre\_loc_i^l - gt\_loc_j^l) \quad (3)$$

样本权重通过调整反向传播中使用的参数的梯度来影响 SWIPENet 的特征学习。

$$\frac{\partial L}{\partial w_{cnn}} = \frac{\alpha_1}{Num} \sum_{i \in Pos} f(\bar{w}_i^m) \nabla_{w_{cnn}}^{L_{cls\_pos}^i} + \frac{\alpha_1}{Num} \sum_{i \in Neg} \nabla_{w_{cnn}}^{L_{cls\_neg}^i} + \frac{\alpha_2}{Num} \sum_{i \in Pos} f(\bar{w}_i^m) \nabla_{w_{cnn}}^{L_{loc\_pos}^i} \quad (4)$$

通过使用样本权重损失，使得 SWIPENet 的特征学习主要由高权重样本决定，而低权重样本的特征学习则被忽略。

样本重加权可用于解决嘈杂的数据问题。它通常为每个样本分配一个权重，然后优化样本加权的训练损失。

#### Invert Multi-Class Invert Adaboost (IMA)

SWIPENet 可能会丢失或错误地检测到训练集中的某些对象，这些目标对象可能被视为噪声数据。这是因为含有噪声的数据非常模糊，并且与背景相似，因此容易被忽略或检测为背景。如果我们使用这些嘈杂的数据训练 SWIPENet，则性能可能会受到影响，SWIPENet 无法将背景与物体区分开来。图 3 显示了示例测试图像及其通过 SWIPENet 的不正确检测。




Fig. 3. SWIPENet treats backgrounds as objects on URPC2018. Left is the ground truth annotations and right includes detection result by SWIPENet.

为了解决这个问题，受文章《Inverse boosting pruning trees for depression detection on Twitter》（<https://arxiv.org/abs/1906.00398>）的启发提出一种 IMA 算法，以减少不确定对象的权重，以提高 SWIPENet 的检测精度。

IMA 算法首先顺序训练多个基本分类器，并根据其错误率  $E_m$  分配权重值  $\alpha$ 。然后，将由前面的分类器分类错误的样本分配较高的权重，从而使后面的分类器专注于学习这些样本。最后，将所有弱基础分类器组合在一起，形成具有相应权重的整体分类器。IMA 还训练了  $M$  次 SWIPENet，然后将它们整合为一个统一模型。不同的是，在每次训练迭代中，IMA 都会减少丢失对象的权重，以减少这些“干扰”样本的影响

---

**Algorithm 1** SWIPENet with Invert Multi-Class Adaboost

---

**Input:** Training images  $I_{train}$  with ground truth objects  $B = \{b_1, \dots, b_N\}$ , testing images  $I_{test}$ .

**Output:** Detection results  $D$ .

- 1: Initialize the object weights  $w_j^1 = \frac{1}{N}, j = 1, \dots, N$ .
  - 2: **for**  $m = 1$  to  $M$  **do**
  - 3:     • Compute the weights of positive samples using (10).
  - 4:     • Train the  $m$ -th SWIPENet  $G_m$  using (1)-(3).
  - 5:     • Compute the  $m$ -th SWIPENet's error rate  $E_m$  using (5)-(6).
  - 6:     • Compute the  $m$ -th SWIPENet's weight  $\alpha_m$  in the ensemble model using (7).
  - 7:     • Decrease the weights of undetected objects and increase the weights of detected objects using (8).
  - 8: **end for**
  - 9: Get the final detections  $D$  using (9).
  - 10: **return** Detections results  $D$
-

$$E_m = \sum_{j=1}^N w_j^m I(b_j) / \sum_{j=1}^N w_j^m \quad (5)$$

where

$$I(b_j) = \begin{cases} 0, \exists d \in D_m, s.t. b_j.cls = d.cls \wedge IoU(b_j, d) \geq \theta \\ 1, otherwise \end{cases} \quad (6)$$

$$\alpha_m = \log \frac{1 - E_m}{E_m} + \log(C - 1) \quad (7)$$

$$w_j^m \leftarrow \frac{w_j^m}{z_m} \exp(\alpha_m (1 - I(b_j))) \quad (8)$$

$$D = NonMaximumSuppression(\bigcup_{m=1}^M D_m) \quad (9)$$

IMA 算法同时定义了一个线性映射函数将 IMA 权重映射到样本加权损失中使用的权重。

$$f(\bar{w}_i^m) = N * \bar{w}_i^m, 0 < \bar{w}_i^m < 1 \quad (10)$$

实验结果

TABLE I  
ABLATION STUDIES ON URPC2017 AND URPC2018. SKIP INDICATES  
SKIP CONNECTION, AND DILATION INDICATES DILATED CONVOLUTION  
LAYER. MAP INDICATES MEAN AVERAGE PRECISION(%).

Dataset	Network	Skip	Dilation	mAP
URPC2017	UWNet1		✓	40.4
	UWNet2			38.3
	SWIPENeT	✓	✓	42.1
URPC2018	UWNet1		✓	61.2
	UWNet2			58.1
	SWIPENeT	✓	✓	62.2



TABLE II  
THE PERFORMANCE OF SWIPENET (MAP(%)) IN EACH ITERATION OF IMA.

Dataset	IMA iteration	Single	Ensemble
URPC2017	1	42.1	-
	2	44.2	45.0
	3	45.3	46.3
	4	40.5	45.3
	5	37.2	44.2
URPC2018	1	62.2	-
	2	63.3	64.5
	3	62.4	64.0
	4	61.2	62.8
	5	59.3	62.1

TABLE III  
COMPARISON WITH THE STATE-OF-ARTS ON URPC2017.

Methods	Backbone	seacucumber	seaurchin	scallop	mAP
SSD300	VGG16	28.1	51.3	21.2	33.5
SSD512	VGG16	38.4	52.9	15.7	35.7
YOLOv3	DarkNet53	28.4	50.3	22.4	33.7
Faster RCNN	VGG16	27.2	45.0	31.9	34.7
Faster RCNN	ResNet50	31.0	41.4	33.5	35.3
Faster RCNN	ResNet101	26.2	47.7	32.5	35.5
OurFirstSingle	SWIPENeT	43.6	51.3	31.2	42.1
OurBestSingle	SWIPENeT	<b>45.0</b>	49.7	41.3	45.3
OurEnsemble	SWIPENeT	44.4	<b>52.4</b>	<b>42.1</b>	<b>46.3</b>

TABLE IV  
COMPARISON WITH THE STATE-OF-ARTS ON URPC2018.

Methods	Backbone	seacucumber	seaurchin	scallop	starfish	mAP
SSD300	VGG16	38.5	83.0	30.8	75.1	56.9
SSD512	VGG16	44.2	<b>84.4</b>	35.8	78.1	60.6
YOLOv3	DarkNet53	35.7	83.0	34.0	77.9	57.7
Faster RCNN	VGG16	43.3	83.0	32.0	74.5	58.2
Faster RCNN	ResNet50	41.1	83.2	34.5	77.2	59.0
Faster RCNN	ResNet101	44.3	82.5	34.7	77.5	59.8
OurFirstSingle	SWIPENeT	46.4	84.0	40.2	78.2	62.2
OurBestSingle	SWIPENeT	50.3	83.7	39.8	<b>79.4</b>	63.3
OurEnsemble	SWIPENeT	<b>52.8</b>	84.1	<b>42.9</b>	78.0	<b>64.5</b>